

Méthodes de recherche appliquée

Outils, atouts et limites

Olivier Caron

Table of contents

0.1 L'explosion ChatGPT en chiffres (Juillet 2025) (Chatterji et al. 2025)

Pour comprendre pourquoi ce cours est essentiel, il faut saisir deux choses : l'échelle du phénomène et la mutation de ses usages.

0.1.1 L'échelle : un phénomène de masse

- **700 millions** d'utilisateurs actifs par semaine.
- **18 milliards** de messages échangés chaque semaine.
- **x5.8** : Croissance du volume de messages en un an (Juin 2024-2025).
- **Cible jeune** : **46%** des messages proviennent des **18-25 ans**.

0.1.2 La tendance de fond : de la création à la recherche

En un an, les usages ont basculé :

- **L'écriture** (créer, résumer) a vu sa part baisser de 36% à **24%**.
- **La recherche d'infos** a explosé, passant de 14% à **24%**.

Les trois usages majoritaires (près de 80% du total) sont :

1. **Guide pratique** (29%)
2. **Recherche d'infos** (24%)
3. **Écriture** (24%)

💡 L'implication pour ce cours

En moins de deux ans, ChatGPT est passé d'un outil de "création de contenu" à un **concurrent direct de Google pour la recherche d'information**, en particulier chez les jeunes.

0.2 Ce que les chiffres cachent : sociologie et intentions (Chatterji et al. 2025)

Derrière les volumes bruts, une transformation plus subtile est à l'œuvre : celle des **profils**, des **motivations** et des **façons d'utiliser** ChatGPT. Ces tendances bousculent plusieurs idées reçues.

0.2.1 1. Un outil qui s'invite dans le quotidien

L'usage de ChatGPT s'ancre de plus en plus dans la sphère personnelle.

- **70 % des conversations** n'ont aucun lien avec le travail.
- En un an, cette part est passée de 53 % à 70 %.
- Le fossé entre hommes et femmes s'est résorbé : après des débuts à 80 % masculins, l'usage est désormais paritaire (2025).

0.2.2 2. Plus mentor que simple exécutant

Les utilisateurs ne cherchent pas seulement un outil, mais un partenaire de réflexion.

- **49 %** des interactions visent à demander un conseil ou une information utile à la décision.
- **40 %** concernent une tâche de production (écrire, coder...).
- Le rôle de "conseiller" prend de l'ampleur et est perçu comme **plus pertinent et qualitatif**.

0.2.3 3. Les mythes déconstruits

Certains usages très visibles médiatiquement sont en réalité marginaux.

- La **programmation** ne représente que **4,2 %** des messages.
- Le **soutien émotionnel**, à peine **1,9 %**.
- Et au travail, dans deux cas sur trois, l'IA sert à **améliorer un contenu existant**, pas à créer de zéro.

En résumé

ChatGPT s'impose moins comme une “machine à produire” que comme un **compagnon de réflexion et de décision**, présent dans les gestes ordinaires de la vie personnelle et professionnelle.

0.3 Contexte après les deux premières séances

0.3.1 Vos acquis :

1. **Évaluation de l'information** : vous savez distinguer une source scientifique d'une source qui l'est moins et en évaluer la crédibilité.
2. **Compréhension de la production scientifique** : vous comprenez la structure d'un article, la question de recherche, les hypothèses, les résultats, les différents journaux...
3. **Maîtrise des outils traditionnels** : vous pouvez utiliser les bases de données académiques comme Scopus ou la recherche Google Scholar.

0.4 Un petit sondage à main levée...

Qui a déjà entendu parler de...

0.4.1 Applications / produits

- ChatGPT ?
- Mistral ?
- Claude ?
- Gemini ?
- DeepSeek ?
- Qwen ?

0.4.2 Concepts


- LLMs ? (Large Language Models)
- Tokens ?
- Embeddings ?
- RAG (Retrieval-Augmented Generation) ?
- Fine-tuning ?
- Context window ?
- Attention / Transformers ?
- Few-shot / Zero-shot ?
- Chain-of-thought ?

i Notre objectif aujourd'hui

- Passer de la simple connaissance des **produits**...
- ... à la compréhension des **concepts**.
- Pour les utiliser de manière **critique** et **efficace**.

0.5 Pour commencer : de quoi parle-t-on ?

1. **Intelligence Artificielle (IA)** : le grand domaine qui vise à reproduire des comportements "intelligents".
2. **Machine Learning (ML)** : une branche de l'IA où la machine **apprend par l'exemple**. (Jordan and Mitchell 2015)
3. **Réseaux de Neurones** : la technique de ML inspirée du cerveau, qui est la base du Deep Learning. L'apprentissage repose sur des connexions pondérées entre neurones artificiels. (Rumelhart, Hinton, and Williams 1986)
4. **Deep Learning (DL)** : utilise des réseaux de neurones **profonds** (avec de nombreuses couches) (LeCun, Bengio, and Hinton 2015).
5. **IA Générative** : la branche du DL qui se spécialise dans la **création de nouveau contenu** (texte, images...) (Goodfellow et al. 2014)
6. **LLMs** : type particulier de modèle de deep learning entraîné sur d'immenses corpus textuels (Brown et al. 2020)



Ajuster le modèle pour qu'il **colle aux données** (réduire l'erreur), sans "apprendre par cœur" (éviter le **sur-apprentissage**).

Illustration de Caprasi, C. (2023). *Artificial Intelligence, Machine Learning, Deep Learning, GenAI and more. Women in Technology - Medium*. <https://medium.com/womenintechology/ai-c3412c5aa0ac>


1 Comprendre comment fonctionnent les LLMs

1.1 La limite du "sac de mots" (Bag-of-Words)

L'approche **Bag-of-Words** se contente de compter les mots, mais ignore leur sens et leur ordre.

- **Le problème** : le modèle ne comprend pas que des mots sont sémantiquement proches.
- **Exemple** : pour lui, “**roi**” est aussi éloigné de “**reine**” que de “**camion**”.
- **Le défi** : Comment la machine peut-elle apprendre que “**excellent**” est proche de “**superbe**” ?

Bag of Words Model explanation



Example

Corpus:
The dog is happy. The child makes the dog happy. The dog makes the child happy

Tokenization:

D1: [The] [dog] [is] [happy]
D2: [The] [child] [makes] [the] [dog] [happy]
D3: [The] [dog] [makes] [the] [child] [happy]

© AIML.com Research

Documents	Counting word frequencies
D1	the: 1, dog: 1, is: 1, happy: 1
D2	the: 2, dog: 1, makes: 1, child: 1, happy: 1
D3	the: 2, child: 1, makes: 1, dog: 1, happy: 1


Encode	child	dog	happy	is	makes	the	BoW Vector representations
D1	0	1	1	1	0	1	[0,1,1,1,0,1]
D2	1	1	1	0	1	2	[1,1,1,0,1,2]
D3	1	1	1	0	1	2	[1,1,1,0,1,2]

1.2 L'idée de l'embedding : représenter des concepts par des nombres

Avant de voir comment une machine comprend les *mots*, imaginons comment représenter une *personne* en chiffres. C'est le principe de l'**embedding** (ou “plongement”).

1.2.1 1. Une seule dimension

Un test peut donner un score unique, par exemple sur l'axe introversion/extraversion. Ce score devient la première coordonnée du "vecteur de personnalité".




1.2.2 2. Ajouter de la complexité

On change d'échelle : on normalise les valeurs pour s'intéresser uniquement à la direction du vecteur (qui porte le sens), pas à sa longueur.

Extraversion




Introversion



1.2.3 3. Vers N dimensions

Les tests comme le *Big Five* utilisent au moins 5 dimensions. En machine learning, on peut en avoir des milliers. La personnalité devient un **vecteur de nombres**, chaque valeur représentant un score.



💡 L'idée fondamentale de l'embedding

Un concept complexe (une personne, un mots, des phrases) peut être représenté par un **vecteur numérique**.

Avantage : les machines peuvent **mesurer les similarités** en comparant ces vecteurs.

Source des illustrations Word2Vec: Alammar, J. (2019). *The Illustrated Word2Vec*. <https://jalammar.github.io/illustrated-word2vec/>


1.3 Comment la machine “compare” les personnalités ?

Maintenant que chaque personne est un vecteur de nombres, on peut utiliser un outil mathématique simple pour calculer à quel point elles sont “proches” en termes de personnalité : la **similarité cosinus**.

1.3.1 1. L'intuition : l'angle

L'idée n'est pas de mesurer la distance entre les points, mais plutôt l'**angle** entre les flèches (vecteurs).

- **Angle faible** (directions similaires) **Score de similarité élevé.**
- **Angle grand** (directions opposées) **Score de similarité faible/négatif.**



1.3.2 2. Le calcul en action

La fonction `cosine_similarity` nous donne un score entre -1 (opposés) et 1 (identiques).

$$\text{cosine_similarity}(\text{Jay}, \text{Person \#1}) = 0.87 \quad \checkmark$$

$$\text{cosine_similarity}(\text{Jay}, \text{Person \#2}) = -0.20$$

$\text{cosine_similarity}(\text{Jay}, \text{Person \#1}) = 0.66$ ✓

$\text{cosine_similarity}(\text{Jay}, \text{Person \#2}) = -0.37$

On voit que **Jay** est bien plus **similaire** à la **Personne #1** qu'à la **Personne #2**, que ce soit avec 2 ou 5 dimensions !

i L'avantage clé

Peu importe le nombre de dimensions (2, 5, plusieurs centaines ou milliers pour les modèles de langue !), la **similarité cosinus** nous donne un **score unique et fiable** pour quantifier la ressemblance entre deux concepts. C'est la base de nombreuses applications : moteurs de recommandation, recherche sémantique... et bien plus encore.

1.4 La révolution Word2Vec : le sens par le contexte


"You shall know a word by the company it keeps" (Firth 1957)

Un mot prend son sens des mots qui l'entourent (Harris 1954).


Cette idée inspire les modèles d'**embeddings**, où chaque mot est représenté par un vecteur numérique.

- Bengio et al. (2003) ont proposé le premier modèle neuronal apprenant ces représentations de mots.
- Mikolov et al. (2013) ont simplifié cette approche avec **Word2Vec**, rendant l'apprentissage des vecteurs rapide et efficace.

Le résultat : les mots apparaissant dans des contextes similaires finissent par avoir des vecteurs proches dans l'espace sémantique.



CBOW



Skipgram

Même si leurs idées sont proches, Harris et Firth ne disent pas la même chose. En résumé :

- **Harris** a fourni la **méthode technique** : son hypothèse distributionnelle est une technique formelle basée sur les statistiques de cooccurrence des mots.
- **Firth** a fourni le **cadre philosophique** : sa théorie contextuelle du sens est plus large, considérant le sens comme l'usage d'un mot dans une situation sociale.

On les cite souvent ensemble car Harris justifie la méthode statistique de Word2Vec, tandis que Firth donne l'intuition fondamentale que le contexte est la clé du sens.

1.5 Visualiser un embedding 1/3


This is a word embedding for the word “king” (GloVe vector trained on Wikipedia):

```
[ 0.50451 , 0.68607 , -0.59517 , -0.022801, 0.60046 , -0.13498 , -0.08813 , 0.47377 , -0.61798 , -0.31012 ,  
-0.076666, 1.493 , -0.034189, -0.98173 , 0.68229 , 0.81722 , -0.51874 , -0.31503 , -0.55809 , 0.66421 , 0.1961  
, -0.13495 , -0.11476 , -0.30344 , 0.41177 , -2.223 , -1.0756 , -1.0783 , -0.34354 , 0.33505 , 1.9927 ,  
-0.04234 , -0.64319 , 0.71125 , 0.49159 , 0.16754 , 0.34344 , -0.25663 , -0.8523 , 0.1661 , 0.40102 , 1.1685 ,  
-1.0137 , -0.21585 , -0.15155 , 0.78321 , -0.91241 , -1.6106 , -0.64426 , -0.51042 ]
```

It's a list of 50 numbers. We can't tell much by looking at the values. But let's visualize it a bit so we can compare it other word vectors. Let's put all these numbers in one row:



Let's color code the cells based on their values (red if they're close to 2, white if they're close to 0, blue if they're close to -2):




1.6 Visualiser un embedding 2/3


Chaque mot est représenté par un **vecteur de nombres** (par ex. 50 ou 300 dimensions). Pris séparément, ces valeurs n'ont pas de sens pour nous. Mais en comparant plusieurs mots, on voit apparaître des **motifs de similarité**.

- *man* et *woman* → vecteurs proches.
- *king* et *queen* → partagent des dimensions → idée de **royauté**.
- *boy* et *girl* → proches sur d'autres dimensions → idée de **jeunesse**.
- *water* → se distingue nettement des mots “personnes”.

Les embeddings capturent des **régularités invisibles**, uniquement à partir des contextes.



1.7 Visualiser un embedding 3/3



Source : *Transformers, the tech behind LLMs - Deep Learning, Chapter 5.*


[Vidéo Youtube](#)

1.8 Analogies vectorielles

Les vecteurs de mots se combinent algébriquement. Ce n'est pas magique : la **géométrie des vecteurs** encode des relations sémantiques et syntaxiques.

- $V(\text{roi}) - V(\text{homme}) + V(\text{femme}) \approx V(\text{reine})$
- $V(\text{Paris}) - V(\text{France}) + V(\text{Italie}) \approx V(\text{Rome})$

Avec des bibliothèques comme **Gensim en python** ou **word2vec en R**, on peut réellement calculer ces analogies et retrouver les mots les plus proches.



1.8.1 Applications concrètes possibles pour une revue de littérature

- Formuler sa recherche comme une **vraie question**, pas juste une liste de mots-clés.
- “Scanner” 100 abstracts en 1 minute pour en extraire les **méthodologies et conclusions**.
- Se faire recommander des articles sémantiquement proches d’articles identifiés comme **fondateurs**.
- Et surtout comprendre la **logique interne** de la plupart outils IA utilisés ensuite.

1.9 Applications Embeddings (SLR + Master Dauphine)

Démo images_interactives

1.10 Le mécanisme d'attention (Vaswani et al. 2017)

L'idée fondamentale des Transformers est simple : pour comprendre un mot, le modèle doit **porter son attention** sur les autres mots importants de la phrase.

Imaginez que pour chaque mot, on fasse un éclairage sur les autres termes qui lui donnent son sens.

Exemple :

"Le livreur a déposé le colis devant la porte, car il était trop lourd."

Pour comprendre le mot **“il”**, le modèle va apprendre à porter son attention sur :

- **“colis”** (très forte attention : c'est l'antécédent le plus probable !)
- **“livreur”** (un peu d'attention : c'est un autre acteur, mais moins pertinent pour “il”)
- **“lourd”** (attention moyenne : c'est une caractéristique qui justifie le “il”)

<https://www.youtube.com/watch?v=wjZofJX0v4M>

1.11.2 Le mécanisme d'Attention

Cette seconde vidéo se concentre sur le concept crucial de l'attention, permettant au modèle de “comprendre” le contexte.

<https://www.youtube.com/watch?v=eMlx5fFNoYc>

1.12 Comment un LLM apprend-il ? Le jeu du mot suivant

L'entraînement d'un LLM comme GPT-4 repose sur un principe simple, répété des milliards de fois sur un corpus gigantesque.

La tâche : prédire le token le plus probable.

1. On lui donne un début de phrase (un “prompt”) :

"Le client a contacté le service après-vente car son produit était..."

2. Le modèle calcule une distribution de probabilité sur l'ensemble de son vocabulaire pour le mot suivant.
 - **défectueux** : 15% de probabilité
 - **cassé** : 12% de probabilité
 - **livré** : 5% de probabilité
 - **incroyable**: 0.1% de probabilité
 - **manger** : 0.0001% de probabilité
 - ...


De la prédiction à l'émergence des capacités

En répétant ce “jeu” des milliards de fois, le modèle apprend les régularités du langage : grammaire, faits, styles d'écriture, voire certaines capacités de raisonnement **émergentes** (Zoph et al. 2022).

Ce type d'apprentissage, fondé sur la prédiction à partir de texte brut, est appelé **auto-**

supervision (*self-supervised learning*).

1.13 Visualisation de GPT-3 (3Blue1Brown (Grant Sanderson))



1.14 Quel LLM choisir ? Quelques concepts clés

1.14.1 Pourquoi ces concepts sont cruciaux ?

- Ils expliquent **pourquoi** certains outils excellent dans certaines tâches
- Ils vous aident à **choisir le bon outil** pour votre besoin
- Ils vous permettent d'**anticiper les limites** avant de les rencontrer
- Ils constituent le vocabulaire de base pour comprendre les nouveautés à venir

1.14.2 Quelques concepts clés

1. **Fenêtre de contexte** : La mémoire de travail de l'IA
2. **RAG** : l'IA accède à des informations externes
3. **Fine-tuning** : comment spécialiser/adapter un modèle
4. **Agents** : l'IA qui agit de manière autonome en utilisant des outils

i Comment évaluer les performances des LLMs ?

Il existe une **multiplicité de benchmarks**, chacun ciblant des compétences différentes (connaissances, raisonnement, recherche d'info, agenticité, etc.).

Exemples représentatifs et **vérifiés** :

- **MMLU** - 57 matières académiques, QCM de culture générale et spécialisée (Hendrycks et al. 2021).
- **GPQA** - Questions de niveau doctorat en physique/chimie/biologie, « Google-proof » (Rein et al. 2023).
- **GAIA** - Benchmark d'**agents** pour questions “réelles” nécessitant outils, web et multimodalité (Mialon et al. 2023).
- **MathArena** - Plateforme/leaderboard évaluant le **raisonnement mathématique** sur concours/récents (IMO, etc.) (Balunović et al. 2025).
- **BEIR** - Évaluation **IR** (recherche d'info) hétérogène, 18 datasets, zéro-shot (Thakur et al. 2021).
- **LoTTE** - Évaluation IR sur **sujets long-tail** (StackExchange), complément de BEIR (Santhanam et al. 2021).

Interprétez toujours les scores **par rapport à la tâche ciblée** : un bon score MMLU ne garantit pas de bonnes performances en **recherche d'articles** (IR/RAG), et inversement.

1.15 Le problème des benchmarks des LLM et des agents

“Today’s benchmarks measure what is easy to measure, not what matters.”
(Kapoor et al. 2024)

- Les benchmarks actuels donnent souvent une **image trop flatteuse** des performances des agents IA.
- Ils ne mesurent pas toujours les éléments essentiels comme :
 - le **coût réel** (temps, tokens),
 - la **robustesse** face à des variations imprévues,
 - la **reproductibilité** des résultats.

- Ce qui brille dans un leaderboard n'est pas forcément ce qui **fonctionne dans la vraie vie**.

Une vidéo intéressante sur ce sujet

« En fait, les LLMs ne stagnent pas du tout » - Vidéo de Micode avec Grégoire Mialon et Clémentine Fourier.

https://www.youtube.com/watch?v=biZX5cnQ_UU

1.16 1. La fenêtre de contexte : la mémoire limitée des LLMs

“Language models struggle to use information located in the middle of long contexts, a phenomenon known as ‘lost in the middle.’” (Liu et al. 2023)

La **fenêtre de contexte** correspond à la quantité maximale de texte qu'un LLM peut traiter en une seule fois

(prompt + réponse), mesurée en **tokens**. Les capacités des LLMs évoluent très vite.

Lost in the Middle: How Language Models Use Long Contexts

Nelson F. Liu^{1*} Kevin Lin² John Hewitt¹ Ashwin Paranjape³
Michele Bevilacqua³ Fabio Petroni³ Percy Liang¹

¹Stanford University ²University of California, Berkeley ³Samaya AI
nfliu@cs.stanford.edu

Abstract

While recent language models have the ability to take long contexts as input, relatively little is known about how well they *use* longer context. We analyze the performance of language models on two tasks that require identifying relevant information in their input contexts: multi-document question answering and key-value retrieval. We find that performance can degrade significantly when changing the position of relevant information, indicating that current language models do not robustly make use of information in long input contexts. In particular, we observe that performance is often highest when relevant information occurs at the beginning or end of the input context, and significantly degrades when models must access relevant information in the middle of long contexts, even for explicitly long-context models. Our analysis provides a better understanding of how language models use their input context and provides new evaluation protocols for future long-context language models.




Figure 1: Changing the location of relevant information (in this case, the position of the passage that answers an input question) within the language model’s input context results in a U-shaped performance curve—models are better at using relevant information that occurs at the very beginning (primacy bias) or end of its input context (recency bias), and performance degrades significantly when models must access and use information located in the middle of its input context.

Fiction.LiveBench for Long Context Deep Comprehension

<https://fiction.live/stories/Fiction-liveBench-Sept-29-2025/oQdzQvKHw8JyXbN87>

Model	0	400	1k	2k	4k	8k	16k	32k	60k	120k	192k
gpt-oss-120b-high [chutes]	100.0	75.0	61.1	55.6	52.8	47.2	44.4	44.4	38.9	-	-
gpt-5	100.0	97.2	94.4	97.2	97.2	100.0	97.2	97.2	100.0	96.9	87.5
gpt-5-mini	100.0	97.2	88.9	80.6	77.8	66.7	69.4	63.9	61.1	62.5	59.4
gpt-5-nano	75.0	58.3	63.9	50.0	50.0	52.8	44.4	47.2	36.1	21.9	34.4
o3	100.0	100.0	100.0	100.0	100.0	100.0	88.9	100.0	83.3	100.0	58.1
o4-mini	100.0	100.0	100.0	100.0	77.8	66.7	77.8	55.6	66.7	62.5	43.8
claude-opus-4:thinking	100.0	94.4	97.2	94.4	94.4	83.3	69.4	80.6	69.4	62.5	-
claude-sonnet-4:thinking	100.0	100.0	100.0	97.2	100.0	97.2	100.0	91.7	94.4	81.3	-
deepseek-r1-0528:free	100.0	91.7	83.3	82.9	88.9	86.1	75.0	69.4	58.3	-	-
deepseek-chat-v3.1 [reasoning: high] [deepseek]	100.0	100.0	94.4	86.1	91.7	80.6	72.2	63.9	58.3	62.5	
deepseek-v3.2-exp [reasoning: high] [deepseek]	100.0	100.0	97.2	97.2	91.7	94.4	83.3	83.3	71.4		
gemini-2.5-flash-lite-preview-06-17:thinking	100.0	66.7	52.8	52.8	55.6	47.2	47.2	44.4	27.8	21.9	37.5
gemini-2.5-flash	100.0	94.4	88.9	86.1	77.8	69.4	80.6	69.4	63.9	65.6	78.1
gemini-2.5-pro-preview-06-05	100.0	100.0	100.0	97.2	94.4	80.6	91.7	91.7	83.3	87.5	90.6
minimax-m1	87.5	86.1	94.4	91.7	88.9	69.4	69.4	72.2	58.3	59.4	71.9
qwen3-235b-a22b-thinking-2507 [chutes]	100.0	100.0	91.7	86.1	91.7	97.2	75.0	80.6	77.8	68.8	
qwen3-30b-a3b-thinking-2507 [chutes]	100.0	86.1	75.0	58.3	58.3	52.8	47.2	52.8	47.2	53.1	-
qwen3-next-80b-a3b-thinking [deepinfra/bf16]	100.0	75.0	72.2	63.9	61.1	58.3	55.6	52.8	55.6	62.5	46.9
qwq-32b:free	100.0	91.7	94.4	88.9	94.4	86.1	83.3	80.6	61.1	-	
qwen3-235b-a22b:free	100.0	90.0	89.3	80.0	69.0	66.7	67.7	-	-	-	

1.17 2. RAG

Le **Retrieval-Augmented Generation** combine recherche et génération.

1. Le LLM **cherche** d'abord des informations dans une base externe (web, PDFs, articles...).
2. Il **injecte** ces informations dans son contexte.
3. Il **génère** une réponse basée sur ces sources.