

Méthodes de recherche appliquée

Outils, atouts et limites

Olivier Caron

Paris Dauphine - PSL

L'explosion ChatGPT en chiffres (Juillet 2025) (Chatterji et al. 2025)

Pour comprendre pourquoi ce cours est essentiel, il faut saisir deux choses : l'échelle du phénomène et la mutation de ses usages.

L'échelle : un phénomène de masse

- **700 millions** d'utilisateurs actifs par semaine.
- **18 milliards** de messages échangés chaque semaine.
- **x5.8** : Croissance du volume de messages en un an (Juin 2024-2025).
- **Cible jeune** : **46%** des messages proviennent des **18-25 ans**.

La tendance de fond : de la création à la recherche

En un an, les usages ont basculé :

- **L'écriture** (créer, résumer) a vu sa part baisser de 36% à **24%**.
- **La recherche d'infos** a explosé, passant de 14% à **24%**.

Les trois usages majoritaires (près de 80% du total) sont :

1. **Guide pratique** (29%)
2. **Recherche d'infos** (24%)
3. **Écriture** (24%)

L'implication pour ce cours

En moins de deux ans, ChatGPT est passé d'un outil de "création de contenu" à un **concurrent direct de Google pour la recherche d'information**, en particulier chez les jeunes.

Ce que les chiffres cachent : sociologie et intentions (Chatterji et al. 2025)

Derrière les volumes bruts, une transformation plus subtile est à l'œuvre : celle des **profils**, des **motivations** et des **façons d'utiliser** ChatGPT. Ces tendances bousculent plusieurs idées reçues.

1. Un outil qui s'invite dans le quotidien

L'usage de ChatGPT s'ancre de plus en plus dans la sphère personnelle.

- **70 % des conversations** n'ont aucun lien avec le travail.
- En un an, cette part est passée de 53 % à 70 %.
- Le fossé entre hommes et femmes s'est résorbé : après des débuts à 80 % masculins, l'usage est désormais paritaire (2025).

2. Plus mentor que simple exécutant

Les utilisateurs ne cherchent pas seulement un outil, mais un partenaire de réflexion.

- **49 %** des interactions visent à demander un conseil ou une information utile à la décision.
- **40 %** concernent une tâche de production (écrire, coder...).
- Le rôle de "conseiller" prend de l'ampleur et est perçu comme **plus pertinent et qualitatif**.

3. Les mythes déconstruits

Certains usages très visibles médiatiquement sont en réalité marginaux.

- La **programmation** ne représente que **4,2 %** des messages.
- Le **soutien émotionnel**, à peine **1,9 %**.
- Et au travail, dans deux cas sur trois, l'IA sert à **améliorer un contenu existant**, pas à créer de zéro.

En résumé

ChatGPT s'impose moins comme une "machine à produire" que comme un **compagnon de réflexion et de décision**, présent dans les gestes ordinaires de la vie personnelle et professionnelle.

Contexte après les deux premières séances

Vos acquis :

1. **Évaluation de l'information** : vous savez distinguer une source scientifique d'une source qui l'est moins et en évaluer la crédibilité.
2. **Compréhension de la production scientifique** : vous comprenez la structure d'un article, la question de recherche, les hypothèses, les résultats, les différents journaux...
3. **Maîtrise des outils traditionnels** : vous pouvez utiliser les bases de données académiques comme Scopus ou la recherche Google Scholar.

Un petit sondage à main levée...

Qui a déjà entendu parler de...

Applications / produits

-  ChatGPT ?
-  Mistral ?
-  Claude ?
-  Gemini ?
-  DeepSeek ?
-  Qwen ?

Concepts


- LLMs ? (Large Language Models)
- Tokens ?
- Embeddings ?
- RAG (Retrieval-Augmented Generation) ?
- Fine-tuning ?
- Context window ?
- Attention / Transformers ?
- Few-shot / Zero-shot ?
- Chain-of-thought ?

Notre objectif aujourd'hui

- Passer de la simple connaissance des **produits**...
- ... à la compréhension des **concepts**.
- Pour les utiliser de manière **critique** et **efficace**.

Pour commencer : de quoi parle-t-on ?

1. **Intelligence Artificielle (IA)** : le grand domaine qui vise à reproduire des comportements “intelligents”.
2. **Machine Learning (ML)** : une branche de l’IA où la machine apprend par l’exemple. ([Jordan and Mitchell 2015](#))
3. **Réseaux de Neurones** : la technique de ML inspirée du cerveau, qui est la base du Deep Learning. L’apprentissage repose sur des connexions pondérées entre neurones artificiels. ([Rumelhart, Hinton, and Williams 1986](#))
4. **Deep Learning (DL)** : utilise des réseaux de neurones profonds (avec de nombreuses couches) ([LeCun, Bengio, and Hinton 2015](#)).
5. **IA Générative** : la branche du DL qui se spécialise dans la création de nouveau contenu (texte, images...) ([Goodfellow et al. 2014](#))
6. **LLMs** : type particulier de modèle de deep learning entraîné sur d’immenses corpus textuels ([Brown et al. 2020](#))



Ajuster le modèle pour qu’il **colle aux données** (réduire l’erreur), sans “apprendre par cœur” (éviter le **sur-apprentissage**).


Comprendre comment fonctionnent les LLMs

La limite du “sac de mots” (Bag-of-Words)


L'approche **Bag-of-Words** se contente de compter les mots, mais ignore leur sens et leur ordre.

- **Le problème** : le modèle ne comprend pas que des mots sont sémantiquement proches.
- **Exemple** : pour lui, “**roi**” est aussi éloigné de “**reine**” que de “**camion**”.
- **Le défi** : Comment la machine peut-elle apprendre que “**excellent**” est proche de “**superbe**” ?

Bag of Words Model explanation



Example




L'idée de l'embedding : représenter des concepts par des nombres

Avant de voir comment une machine comprend les *mots*, imaginons comment représenter une *personne* en chiffres. C'est le principe de l'**embedding** (ou "plongement").

1. Une seule dimension

Un test peut donner un score unique, par exemple sur l'axe introversion/extraversion. Ce score devient la première coordonnée du "vecteur de personnalité".




2. Ajouter de la complexité

On change d'échelle : on normalise les valeurs pour s'intéresser uniquement à la direction du vecteur (qui porte le sens), pas à sa longueur.



3. Vers N dimensions

Les tests comme le *Big Five* utilisent au moins 5 dimensions. En machine learning, on peut en avoir des milliers. La personnalité devient un **vecteur de nombres**, chaque valeur représentant un score.



L'idée fondamentale de l'embedding

Un concept complexe (une personne, un mots, des phrases) peut être représenté par un **vecteur numérique**.

Avantage : les machines peuvent **mesurer les similarités** en comparant ces vecteurs.


Comment la machine “compare” les personnalités ?

Maintenant que chaque personne est un vecteur de nombres, on peut utiliser un outil mathématique simple pour calculer à quel point elles sont “proches” en termes de personnalité : la **similarité cosinus**.

1. L'intuition : l'angle ⚠

L'idée n'est pas de mesurer la distance entre les points, mais plutôt l'**angle** entre les flèches (vecteurs).

- **Angle faible** (directions similaires) → **Score de similarité élevé**.
- **Angle grand** (directions opposées) → **Score de similarité faible/négatif**.



2. Le calcul en action

La fonction `cosine_similarity` nous donne un score entre -1 (opposés) et 1 (identiques).

`cosine_similarity( Jay, Person #1 ) = 0.87` ✓

`cosine_similarity( Jay, Person #2 ) = -0.20`

`cosine_similarity( Jay, Person #1 ) = 0.66` ✓

`cosine_similarity( Jay, Person #2 ) = -0.37`

On voit que **Jay** est bien plus **similaire** à la **Personne #1** qu'à la **Personne #2**, que ce soit avec 2 ou 5 dimensions !

i L'avantage clé

Peu importe le nombre de dimensions (2, 5, plusieurs centaines ou milliers pour les modèles de langue !), la **similarité cosinus** nous donne un **score unique et fiable** pour quantifier la ressemblance entre deux concepts. C'est la base de nombreuses applications : moteurs de recommandation, recherche sémantique... et bien plus encore.



La révolution Word2Vec : le sens par le contexte

"You shall know a word by the company it keeps" (Firth 1957)

Un mot prend son sens des mots qui l'entourent (Harris 1954).

Cette idée inspire les modèles d'**embeddings**, où chaque mot est représenté par un vecteur numérique.

- Bengio et al. (2003) ont proposé le premier modèle neuronal apprenant ces représentations de mots.
- Mikolov et al. (2013) ont simplifié cette approche avec **Word2Vec**, rendant l'apprentissage des vecteurs rapide et efficace.


Le résultat : les mots apparaissant dans des contextes similaires finissent par avoir des vecteurs proches dans l'espace sémantique.

Visualiser un embedding 1/3


This is a word embedding for the word “king” (GloVe vector trained on Wikipedia):

```
[ 0.50451 , 0.68607 , -0.59517 , -0.022801, 0.60046 , -0.13498 , -0.08813 , 0.47377 , -0.61798 , -0.31012 ,  
-0.076666, 1.493 , -0.034189, -0.98173 , 0.68229 , 0.81722 , -0.51874 , -0.31503 , -0.55809 , 0.66421 , 0.1961  
, -0.13495 , -0.11476 , -0.30344 , 0.41177 , -2.223 , -1.0756 , -1.0783 , -0.34354 , 0.33505 , 1.9927 ,  
-0.04234 , -0.64319 , 0.71125 , 0.49159 , 0.16754 , 0.34344 , -0.25663 , -0.8523 , 0.1661 , 0.40102 , 1.1685 ,  
-1.0137 , -0.21585 , -0.15155 , 0.78321 , -0.91241 , -1.6106 , -0.64426 , -0.51042 ]
```

It’s a list of 50 numbers. We can’t tell much by looking at the values. But let’s visualize it a bit so we can compare it other word vectors. Let’s put all these numbers in one row:



Let’s color code the cells based on their values (red if they’re close to 2, white if they’re close to 0, blue if they’re close to -2):






Visualiser un embedding 2/3


Chaque mot est représenté par un **vecteur de nombres** (par ex. 50 ou 300 dimensions). Pris séparément, ces valeurs n'ont pas de sens pour nous. Mais en comparant plusieurs mots, on voit apparaître des **motifs de similarité**.

- *man* et *woman* → vecteurs proches.
- *king* et *queen* → partagent des dimensions → idée de **royauté**.
- *boy* et *girl* → proches sur d'autres dimensions → idée de **jeunesse**.
- *water* → se distingue nettement des mots "personnes".

💡 Les embeddings capturent des **régularités invisibles**, uniquement à partir des contextes.



Visualiser un embedding 3/3



Analogies vectorielles

Les vecteurs de mots se combinent algébriquement. Ce n'est pas magique : la **géométrie des vecteurs** encode des relations sémantiques et syntaxiques.

- $V(\text{roi}) - V(\text{homme}) + V(\text{femme}) \approx V(\text{reine})$
- $V(\text{Paris}) - V(\text{France}) + V(\text{Italie}) \approx V(\text{Rome})$

Avec des bibliothèques comme **Gensim en python** ou **word2vec en R**, on peut réellement calculer ces analogies et retrouver les mots les plus proches.

king - man + woman ≈ queen



Applications concrètes possibles pour une revue de littérature

- Formuler sa recherche comme une **vraie question**, pas juste une liste de mots-clés.
- “Scanner” 100 abstracts en 1 minute pour en extraire les **méthodologies et conclusions**.
- Se faire recommander des articles sémantiquement proches d’articles identifiés comme **fondateurs**.
- Et surtout comprendre la **logique interne** de la plupart outils IA utilisés ensuite.

Applications Embeddings (SLR + Master Dauphine)

Démo `images_interactives`

Le mécanisme d'attention (Vaswani et al. 2017)

L'idée fondamentale des Transformers est simple : pour comprendre un mot, le modèle doit **porter son attention** sur les autres mots importants de la phrase.

Imaginez que pour chaque mot, on fasse un éclairage 🔦 sur les autres termes qui lui donnent son sens.

Exemple :


"Le livreur a déposé le colis devant la porte, car il était trop lourd."

Pour comprendre le mot **"il"**, le modèle va apprendre à porter son attention sur :

- **"colis"** (très forte attention : c'est l'antécédent le plus probable !)
- **"livreur"** (un peu d'attention : c'est un autre acteur, mais moins pertinent pour "il")
- **"lourd"** (attention moyenne : c'est une caractéristique qui justifie le "il")

💡 La grande différence

Contrairement à Word2Vec qui regarde une petite fenêtre fixe, l'**attention** permet de créer des liens sémantiques entre des mots **même très éloignés** dans la phrase. Le modèle apprend quelles parties du contexte sont les plus pertinentes.



The FBI is chasing a criminal on the run .
The FBI is chasing a criminal on the run .
The FBI is chasing a criminal on the run .
The FBI is chasing a criminal on the run .
The FBI is chasing a criminal on the run .
The FBI is chasing a criminal on the run .
The FBI is chasing a criminal on the run .
The FBI is chasing a criminal on the run .
The FBI is chasing a criminal on the run .


Figure 4. The relation of words in a sentence raising the need for composite embedding. The credit of this image for (Cheng et al., 2016).

Pour aller plus loin : les Transformers (3Blue1Brown (Grant Sanderson))

Ces deux vidéos sont fortement recommandées pour une compréhension visuelle et approfondie des concepts clés des Transformers.


L'architecture "Transformers"

Cette vidéo offre une vue d'ensemble de l'architecture Transformer, le moteur des grands modèles de langage modernes.



Le mécanisme d'Attention

Cette seconde vidéo se concentre sur le concept crucial de l'attention, permettant au modèle de "comprendre" le contexte.



Comment un LLM apprend-il ? Le jeu du mot suivant

L'entraînement d'un LLM comme GPT-4 repose sur un principe simple, répété des milliards de fois sur un corpus gigantesque.

La tâche : prédire le token le plus probable.

1. On lui donne un début de phrase (un "prompt") :

"Le client a contacté le service après-vente car son produit était..."

2. Le modèle calcule une distribution de probabilité sur l'ensemble de son vocabulaire pour le mot suivant.


- **défectueux** : 15% de probabilité
- **cassé** : 12% de probabilité
- **livré** : 5% de probabilité
- **incroyable** : 0.1% de probabilité
- **manger** : 0.0001% de probabilité
- ...

De la prédiction à l'émergence des capacités

En répétant ce "jeu" des milliards de fois, le modèle apprend les régularités du langage : grammaire, faits, styles d'écriture, voire certaines capacités de raisonnement **émergentes** ([Zoph et al. 2022](#)).

Ce type d'apprentissage, fondé sur la prédiction à partir de texte brut, est appelé **auto-supervision** (*self-supervised learning*).

Visualisation de GPT-3 (3Blue1Brown (Grant Sanderson))



Quel LLM choisir ? Quelques concepts clés

Pourquoi ces concepts sont cruciaux ?

- Ils expliquent **pourquoi** certains outils excellent dans certaines tâches
- Ils vous aident à **choisir le bon outil** pour votre besoin
- Ils vous permettent d'**anticiper les limites** avant de les rencontrer
- Ils constituent le vocabulaire de base pour comprendre les nouveautés à venir

Quelques concepts clés

1. **Fenêtre de contexte** : La mémoire de travail de l'IA
2. **RAG** : l'IA accède à des informations externes
3. **Fine-tuning** : comment spécialiser/adapter un modèle
4. **Agents** : l'IA qui agit de manière autonome en utilisant des outils

Comment évaluer les performances des LLMs ?

Il existe une **multiplicité de benchmarks**, chacun ciblant des compétences différentes (connaissances, raisonnement, recherche d'info, agenticité, etc.).

Exemples représentatifs et **vérifiés** :

- **MMLU** - 57 matières académiques, QCM de culture générale et spécialisée ([Hendrycks et al. 2021](#)).
- **GPQA** - Questions de niveau doctorat en physique/chimie/biologie, « Google-proof » ([Rein et al. 2023](#)).
- **GAIA** - Benchmark d'**agents** pour questions "réelles" nécessitant outils, web et multimodalité ([Mialon et al. 2023](#)).
- **MathArena** - Plateforme/leaderboard évaluant le **raisonnement mathématique** sur concours/récents (IMO, etc.) ([Balunović et al. 2025](#)).
- **BEIR** - Évaluation **IR** (recherche d'info) hétérogène, 18 datasets, zéro-shot ([Thakur et al. 2021](#)).
- **LoTTE** - Évaluation **IR** sur **sujets long-tail** (StackExchange), complément de BEIR ([Santhanam et al. 2021](#)).

 Interprétez toujours les scores **par rapport à la tâche ciblée** : un bon score MMLU ne garantit pas de bonnes performances en **recherche d'articles** (IR/RAG), et inversement.

Le problème des benchmarks des LLM et des agents

“Today’s benchmarks measure what is easy to measure, not what matters.”

(Kapoor et al. 2024)

- Les benchmarks actuels donnent souvent une **image trop flatteuse** des performances des agents IA.
- Ils ne mesurent pas toujours les éléments essentiels comme :
 - le **coût réel** (temps, tokens),
 - la **robustesse** face à des variations imprévues,
 - la **reproductibilité** des résultats.
- Ce qui brille dans un leaderboard n’est pas forcément ce qui **fonctionne dans la vraie vie**.

Une vidéo intéressante sur ce sujet 

1. La fenêtre de contexte : la mémoire limitée des LLMs

“Language models struggle to use information located in the middle of long contexts, a phenomenon known as ‘lost in the middle’.” (Liu et al. 2023)

La **fenêtre de contexte** correspond à la quantité maximale de texte qu’un LLM peut traiter en une seule fois (prompt + réponse), mesurée en **tokens**. Les capacités des LLMs évoluent très vite.

Lost in the Middle: How Language Models Use Long Contexts

Nelson F. Liu^{1*} Kevin Lin² John Hewitt¹ Ashwin Paranjape³
Michele Bevilacqua³ Fabio Petroni³ Percy Liang¹
¹Stanford University ²University of California, Berkeley ³Samaya AI
nfliu@cs.stanford.edu

Abstract

While recent language models have the ability to take long contexts as input, relatively little is known about how well they use longer context. We analyze the performance of language models on two tasks that require identifying relevant information in their input contexts: multi-document question answering and key-value retrieval. We find that performance can degrade significantly when changing the position of relevant information in long input contexts. In particular, we observe that performance is often highest when relevant information occurs at the beginning or end of the input context, and significantly degrades when models must access relevant information in the middle of long contexts, even for explicitly long-context models. Our analysis provides a better understanding of how language models use their input context and provides new evaluation protocols for future long-context language models.




Figure 1: Changing the location of relevant information (in this case, the position of the passage that answers an input question) within the language model’s input context results in a U-shaped performance curve—models are better at using relevant information that occurs at the very beginning (primacy bias) or end of its input context (recency bias), and performance degrades significantly when models must access and use information located in the middle of its input context.

Fiction.LiveBench for Long Context Deep Comprehension


<https://fiction.live/stories/Fiction-liveBench-Sept-29-2025/oQdzQvKHw8JyXbN87>

Model	0	400	1k	2k	4k	8k	16k	32k	60k	120k	192k
gpt-oss-120b-high [chutes]	100.0	75.0	61.1	55.6	52.8	47.2	44.4	44.4	38.9	-	-
gpt-5	100.0	97.2	94.4	97.2	97.2	100.0	97.2	97.2	100.0	96.9	87.5
gpt-5-mini	100.0	97.2	88.9	80.6	77.8	66.7	69.4	63.9	61.1	62.5	59.4
gpt-5-nano	75.0	58.3	63.9	50.0	50.0	52.8	44.4	47.2	36.1	21.9	34.4
o3	100.0	100.0	100.0	100.0	100.0	100.0	88.9	100.0	83.3	100.0	58.1
o4-mini	100.0	100.0	100.0	100.0	77.8	66.7	77.8	55.6	66.7	62.5	43.8
claude-opus-4:thinking	100.0	94.4	97.2	94.4	94.4	83.3	69.4	80.6	69.4	62.5	-
claude-sonnet-4:thinking	100.0	100.0	100.0	97.2	100.0	97.2	100.0	91.7	94.4	81.3	-
deepseek-r1-0528:free	100.0	91.7	83.3	82.9	88.9	86.1	75.0	69.4	58.3	-	-
deepseek-chat-v3.1 [reasoning: high] [deepseek]	100.0	100.0	94.4	86.1	91.7	80.6	72.2	63.9	58.3	62.5	
deepseek-v3.2-exp [reasoning: high] [deepseek]	100.0	100.0	97.2	97.2	91.7	94.4	83.3	83.3	71.4		
gemini-2.5-flash-lite-preview-06-17:thinking	100.0	66.7	52.8	52.8	55.6	47.2	47.2	44.4	27.8	21.9	37.5
gemini-2.5-flash	100.0	94.4	88.9	86.1	77.8	69.4	80.6	69.4	63.9	65.6	78.1
gemini-2.5-pro-preview-06-05	100.0	100.0	100.0	97.2	94.4	80.6	91.7	91.7	83.3	87.5	90.6
minimax-m1	87.5	86.1	94.4	91.7	88.9	69.4	69.4	72.2	58.3	59.4	71.9
qwen3-235b-a22b-thinking-2507 [chutes]	100.0	100.0	91.7	86.1	91.7	97.2	75.0	80.6	77.8	68.8	
qwen3-30b-a3b-thinking-2507 [chutes]	100.0	86.1	75.0	58.3	58.3	52.8	47.2	52.8	47.2	53.1	-
qwen3-next-80b-a3b-thinking [deepinfra/bf16]	100.0	75.0	72.2	63.9	61.1	58.3	55.6	52.8	55.6	62.5	46.9
qwq-32b:free	100.0	91.7	94.4	88.9	94.4	86.1	83.3	80.6	61.1	-	
qwen3-235b-a22b:free	100.0	90.0	89.3	80.0	69.0	66.7	67.7	-	-	-	

2. RAG

Le **Retrieval-Augmented Generation** combine recherche et génération.

1. Le LLM **cherche** d'abord des informations dans une base externe (web, PDFs, articles...).
2. Il **injecte** ces informations dans son contexte.
3. Il **génère** une réponse basée sur ces sources.



3. Transfer learning et fine-tuning



« Technique consistant à spécialiser un modèle d'IA pré-entraîné à l'accomplissement d'une tâche spécifique. » (CNIL)

- **Transfer learning** = concept général : réutiliser un modèle pré-entraîné pour une tâche ou un domaine cible.
- **Fine-tuning** = méthode concrète de transfer learning : ré-entraîner (partiellement ou totalement) les poids du modèle sur des données spécifiques.

Exemples illustratifs

- **SciBERT** : Modèle BERT (Devlin et al. 2019) pré-entraîné et affiné sur des articles scientifiques pour mieux traiter le texte biomédical (Beltagy, Lo, and Cohan 2019).
- **SiBERT** : Modèle généraliste affiné sur **272 jeux de données** en anglais pour créer un classificateur robuste (analyse de sentiment) (Hartmann et al. 2023).

Large Language Model



4. Les Agents : l'IA qui agit de manière autonome

“An autonomous agent is a system situated within and a part of an environment that senses that environment and acts on it, over time, in pursuit of its own agenda and so as to effect what it senses in the future.” - (Franklin and Graesser 1997)


- Un **agent IA** combine **raisonnement**, **action** et **interaction avec un environnement**.
- Les **LLM agents** représentent une évolution : ils planifient, mémorisent, utilisent des outils, collaborent et s'adaptent.
- Ils constituent une brique centrale pour l'automatisation avancée de tâches, y compris pour la revue de littérature ou la recherche scientifique.

De l'émergence à la structuration des agents LLM

- **2022** : apparition des premiers agents combinant raisonnement et action (Yao et al. 2023).
- **2023** : diffusion grand public avec les premières implémentations autonomes, notamment via [AutoGPT](#).
- **2024–2025** : agents dotés de mémoire, coordination et rôles spécialisés (Wang et al. 2024; Luo et al. 2025).

i Pour aller plus loin

- Une liste actualisée des travaux est disponible ici : [Awesome Agent Papers](#).



Le coût des LLMs

Modèles et abonnements en octobre 2025

Service	Prix public	Ce que ça débloque / note	Lien
ChatGPT Free	0 €	Accès de base	Site
ChatGPT Plus	~20 \$/mois (facturé en devise locale, TVA selon pays)	Accès élargi aux modèles (GPT-4/o1), fonctionnalités avancées	Site
Claude Pro	17 \$/mois (annuel) ou 20 \$/mois (HT)	Plus d'usage, modèles Claude 3.x/4.x, fonctionnalités pro	Site
Perplexity Pro	20 \$/mois	Accès à des modèles avancés (OpenAI, Anthropic, etc.), recherche approfondie, limites Pro accrues (300+ recherches/jour), gestion de fichiers & collections	Site
Google AI Pro (Gemini)	21,99 €/mois	Gemini 2.5 Pro, NotebookLM, 2 To, Deep Research	Site
Mistral – Le Chat Pro	17,99 €/mois (7,19 € pour étudiants, 12 mois)	Version Pro de “Le Chat”	Site
Elicit Plus	10 \$/mois (annuel) ou 12 \$/mois	Extraction/synthèse, export de données	Site
Elicit Pro	à partir de 42 \$/mois (annuel)	Workflows RL/SLR, quotas plus importants	Site
DeepSeek (API)	0,028 \$/M tokens (cache hit) - 0,28 \$/M (miss) - 0,42 \$/M output		Site



L'art du Prompt Engineering - exemple pour revue de littérature

- **Donner un rôle clair** → aide l'IA à adopter une “posture experte”
Montré comme une bonne pratique dans plusieurs études de synthèse (Vatsal and Dubey 2024; Sahoo et al. 2025)
- **Montrer un exemple** (*few-shot prompting*) → augmente fortement la qualité et la cohérence des réponses
Effet mesuré dans des benchmarks sur des tâches complexes (Vatsal and Dubey 2024)
- **Demander un raisonnement étape par étape** (*chain-of-thought*) → réduit les erreurs factuelles et améliore la profondeur
Résultats solides dans les grandes revues sur le prompt engineering (Schulhoff et al. 2025)
- **Spécifier le format de sortie** → favorise des réponses exploitables directement (tableaux, résumés structurés)
Particulièrement efficace dans les tâches d'extraction d'informations (Jin et al. 2025)

Outils utiles pour la revue de littérature

Bien sûr il existe les LLMs bien connus comme ChatGPT, Claude, Gemini, Mistral, etc. mais certains autres outils spécialisés (et de nombreux autres) :

Outil	Fonction principale	Cas d'usage typique	Lien
Perplexity.ai	Moteur de recherche conversationnel	Obtenir une vue d'ensemble rapide et sourcée sur un sujet, accéder à des modèles récents et à la recherche web temps réel	perplexity.ai
Elicit	Recherche sémantique et extraction automatique d'informations clés	Construire une bibliographie structurée, extraire méthodologies et résultats	elicit.com
NotebookLM	Analyse de documents personnels (RAG)	Interroger vos propres articles PDF et croiser les résultats	notebooklm.google
Scite.ai	Analyse de la qualité des citations (soutient / mentionne / conteste)	Évaluer la robustesse des articles et des théories	scite.ai
Connected Papers	Visualisation des liens entre articles	Explorer le réseau scientifique autour d'un article de départ	connectedpapers.com
Consensus	Synthèse automatisée à partir d'articles scientifiques	Obtenir des réponses à des questions précises basées sur la littérature	consensus.app
ArtiRev	Plateforme académique française pour les revues de littérature	Identifier et organiser les articles d'un champ de recherche	artirev.fr
Litmaps	Cartographie dynamique de la littérature	Visualiser et suivre l'évolution d'un champ de recherche dans le temps	litmaps.com



DÉMONSTRATIONS - thèmes possibles

1. Comment l'usage de l'intelligence artificielle générative transforme-t-il la relation entre marques et consommateurs ?
2. Dans quelle mesure les influenceurs sur les réseaux sociaux façonnent-ils les comportements de consommation des adolescents ?
3. Comment les consommateurs perçoivent-ils les campagnes de communication promouvant la responsabilité environnementale des marques ?
4. Quels sont les effets du télétravail et du digital nomadisme sur la communication interne et la culture organisationnelle ?
5. Comment la marque employeur influence-t-elle la perception et l'engagement des candidats à l'ère de la digitalisation et des nouvelles attentes sociétales ?
6. Pour une marque, est-ce pertinent d'endosser via sa communication des combats portés par des mouvements sociaux (féminisme, antiracisme, écologie radicale, etc.) ?
7. Est-ce que tous les bad buzz provoquent des crises de réputation de marque ?

Le risque majeur : hallucinations et références fantômes

Le problème le plus documenté des LLM est leur tendance à **inventer des informations crédibles** (hallucinations) et à **fabriquer des références** qui semblent plausibles mais sont inexistantes ([Tosi 2025](#)).

- **Références fantômes** : un article a rapporté qu'un outil IA a généré une référence bibliographique complètement inventée lors d'une revue de littérature systématique (SLR) ([Tosi 2025](#)).
 - **Conclusions erronées** : la synthèse produite par l'IA peut être inexacte, déformer les conclusions des sources originales ou manquer de nuances et d'analyse critique ([Li et al. 2025](#); [Tosi 2025](#)).
 - **Dépendance au prompt** : de légères variations dans la formulation d'une requête (le "prompt") peuvent radicalement changer la qualité, la pertinence et même la véracité des résultats obtenus ([Baumann et al. 2025](#)).
1. **Vérifier chaque source** : un DOI, un titre ou un auteur doit correspondre à une publication réelle et accessible.
 2. **Consulter l'article original** avant de citer ou de s'approprier une conclusion synthétisée par une IA.
 3. Privilégier les outils basés sur un **corpus fermé (RAG)**, qui citent leurs sources **OU** LLM + article en contexte.

Le risque caché : le *LLM Hacking*

Le “*LLM Hacking*” décrit comment la sensibilité extrême des IA aux prompts permet, intentionnellement ou non, d’obtenir des **conclusions statistiques erronées** à partir des mêmes données ([Baumann et al. 2025](#)).

En testant quelques configurations de modèles ou de prompts, il devient possible de présenter presque n’importe quel résultat comme statistiquement significatif.

- **Faux positifs** : sur des hypothèses où il n’existe en réalité aucun effet, il est possible de **fabriquer un résultat statistiquement significatif** ($p < 0.05$) dans **94,4 %** des cas en choisissant la bonne combinaison modèle/prompt ([Baumann et al. 2025](#)).
- **Inversion des résultats (erreur de type S)** : il est possible de trouver un effet significatif dans la **direction opposée** à la réalité dans **68,3 %** des cas ([Baumann et al. 2025](#)).
- **Indétectable a posteriori** : une analyse manipulée via le *prompting* peut sembler méthodologiquement rigoureuse, rendant la fraude presque impossible à détecter pour un évaluateur externe.

Implication

La reproductibilité scientifique est menacée. Sans une transparence totale sur les prompts et modèles testés, les résultats d’une recherche assistée par IA peuvent être non fiables.

Biais “silencieux” et “couverture” limitée

Un LLM n'est **jamais neutre**. Il amplifie les biais des données sur lesquelles il a été entraîné.

Biais

- **Biais de corpus** : surreprésentation de la recherche anglo-saxonne et des paradigmes scientifiques dominants, au risque de créer une **monoculture intellectuelle**.
- **Biais de popularité** : tendance à privilégier les articles très cités. Un outil IA a ainsi manqué **100 % des 32 études primaires** d'une revue systématique, ne sélectionnant que des articles plus anciens et trois fois plus cités en moyenne que ceux de la sélection humaine ([Tosi 2025](#)).

Couverture

- **Connaissances datées** : l'IA ne connaît rien au-delà de sa date de “cut-off” (pas toujours rendue publique).
- **L'angle mort des paywalls** : l'accès est limité aux textes en libre accès (résumés, pre-prints), ignorant une part massive de la littérature scientifique.
- **Couverture inégale des disciplines** : les domaines riches en données textuelles sont mieux couverts.

Enjeux éthiques et responsabilité académique


L'utilisation de l'IA engage la responsabilité du chercheur bien au-delà de la simple citation.

- **Confidentialité des données** : ne **jamais** soumettre de données de recherche sensibles, confidentielles ou non publiées sur des services d'IA publics.
- **Risque de déresponsabilisation morale** : déléguer une tâche à une IA, surtout via des instructions vagues, peut **augmenter les comportements malhonnêtes**. Les agents IA sont bien plus enclins à suivre des instructions contraires à l'éthique que les humains ([Köbis et al. 2025](#)).
- **Transparence et paternité** : toujours **déclarer l'utilisation d'outils d'IA** dans la section méthodologique. Un agent conversationnel ne peut être crédité comme auteur.
- **Empreinte environnementale** : l'entraînement et l'utilisation des LLM consomment une quantité d'énergie considérable. La question de l'étiquetage énergétique des modèles d'IA commence à se poser ([Luccioni et al. 2024](#)).

AI'S ENERGY FOOTPRINT

The power consumed by artificial intelligence (AI) tools varies greatly depending on the task. An AI model that provides answers to queries is much less energy-intensive than one that generates images from text prompts, for example. And the data show that even AI models of the same type can vary widely in energy consumption.

● = AI model* | = Mean



*Tests conducted on 20 popular open-source models. Each dot represents one model; †1 Watt-hour represents power consumption of 1 W extended over 1 hour.

Quel gain de temps avec les LLMs ?

L'argument principal en faveur de l'IA est une accélération radicale du processus de recherche. Le schéma ci-contre montre comment l'IA s'intègre dans les étapes les plus chronophages d'une revue systématique.

- **Filtrage accéléré** : un outil comme **ASReview** a permis de réduire de **77 %** le temps de sélection (*screening*) des résumés dans une revue systématique ([Dijk et al. 2023](#)).
- **Synthèse en temps record** : dans des études contrôlées, des agents IA interactifs (**InsightAgent**) ont permis à des cliniciens de réaliser une revue systématique complète en **environ 1h30** ([Qiu et al. 2025](#)).
- **De plusieurs jour à quelques minutes** : le filtrage de plus de 8 300 articles a été réalisé en **moins de 10 minutes** par une architecture multi-LLM ([Joos, Keim, and Fischer 2025](#)).




FIGURE 3. SLR's execution steps enriched with Gen-AI and LLMs support.

Tosi (2025)

💡 Le rôle de l'IA

L'IA est un **accélérateur de recherche** qui automatise les tâches répétitives, mais ne remplace pas le jugement humain pour la planification et l'analyse critique.

Le match : précision contre complétude (rappel)

Pour évaluer un outil de recherche, deux métriques sont essentielles.

Le Rappel (Recall / Sensibilité)

La capacité à trouver **tous** les documents pertinents.

- **Question** : ai-je raté des articles importants ?
- **Objectif** : être exhaustif. 100 % = aucun article pertinent manqué.
- **Risque** : un faible rappel mène à des conclusions biaisées.

La Précision (Precision)

La capacité à ne retourner **que** des documents pertinents.

- **Question** : combien de “bruit” dois-je trier ?
- **Objectif** : être pertinent. 100 % = tous les résultats sont utiles.
- **Risque** : une faible précision fait perdre du temps.

Un outil très exhaustif (**haut rappel**) ramène souvent beaucoup de bruit (**basse précision**). Un outil très ciblé (**haute précision**) peut omettre des références importantes (**bas rappel**).

Évidence empirique

Comparativement aux IA testées (**Elicit**, **SciSpace**), **WoS/Scopus** obtiennent de meilleurs taux de **précision/qualité**, l'IA ramenant plus de références **uniques** mais souvent **moins bien classées** ([Tomczyk et al.](#)).

Un bilan nuancé quant aux performances

Les performances des IA varient énormément selon les outils et les méthodes.

des performances parfois excellentes...

- **Consensus multi-LLM** : en faisant voter plusieurs modèles d'IA, une étude a atteint un **rappel de 98,8 %**, un taux d'erreur inférieur à celui d'un humain ([Joos, Keim, and Fischer 2025](#)).
- **Systèmes interactifs supervisés** : avec l'aide d'un expert, un outil peut atteindre **98,5 % de rappel** ([Qiu et al. 2025](#)).

...mais des échecs critiques et des biais tenaces.

- **Elicit** n'a atteint en moyenne qu'un **rappel de 39,5 %** sur quatre études de cas, le rendant insuffisant pour une revue systématique exhaustive ([Lau and Golder 2025](#)).
- Dans une autre étude, un outil IA a **totallement manqué les 32 études primaires** d'une revue, à cause d'un fort biais de popularité ([Tosi 2025](#)).

L'IA peut **précisément** omettre l'essentiel. Sans supervision humaine et validation croisée, le gain de temps peut se payer par une perte de pertinence et d'exhaustivité.

Conclusion

L'IA ne remplace pas le chercheur, elle transforme son rôle.

- l'IA est un **levier de productivité** majeur, mais non dénué de risques importants.
- la **vigilance critique** (biais, hallucinations, hacking) et la **vérification humaine** sont incontournables.
- choisir **le bon outil pour la bonne tâche** est essentiel (exploration vs. synthèse vs. filtrage).
- l'avenir est à la **collaboration homme-machine**, où l'expertise humaine guide la puissance de l'IA.

Références

- Balunović, Mislav, Jasper Dekoninck, Ivo Petrov, Nikola Jovanović, and Martin Vechev. 2025. “Matharena: Evaluating Lms on Uncontaminated Math Competitions.” *arXiv Preprint arXiv:2505.23281*.
- Baumann, Joachim, Paul Röttger, Aleksandra Urman, Albert Wendsjö, Flor Miriam Plaza-del-Arco, Johannes B Gruber, and Dirk Hovy. 2025. “Large Language Model Hacking: Quantifying the Hidden Risks of Using LLMs for Text Annotation.” *arXiv Preprint arXiv:2509.08825*.
- Beltagy, Iz, Kyle Lo, and Arman Cohan. 2019. “SciBERT: A Pretrained Language Model for Scientific Text.” *arXiv Preprint arXiv:1903.10676*.
- Bengio, Yoshua, Réjean Ducharme, Pascal Vincent, and Christian Jauvin. 2003. “A Neural Probabilistic Language Model.” *Journal of Machine Learning Research* 3 (Feb): 1137–55.
- Brown, Tom, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, et al. 2020. “Language Models Are Few-Shot Learners.” *Advances in Neural Information Processing Systems* 33: 1877–1901.
- Chatterji, Aaron, Tom Cunningham, David Deming, Zoe Hitzig, Christopher Ong, Carl Shan, and Kevin Wadman. 2025. “How People Use ChatGPT.”
- Devlin, Jacob, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2019. “Bert: Pre-Training of Deep Bidirectional Transformers for Language Understanding.” In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, 4171–86.
- Dijk, Sanne HB van, Marjolein GJ Brusse-Keizer, Charlotte C Bucsan, Job van der Palen, Carine JM Doggen, and Anke Lenferink. 2023. “Artificial Intelligence in Systematic Reviews: Promising When Appropriately Used.” *BMJ Open* 13 (7): e072254.

- Firth, J. R. 1957. "A Synopsis of Linguistic Theory 1930-55." *Studies in Linguistic Analysis (Special Volume of the Philological Society)* 1952-59: 132.
- Franklin, Stan, and Art Graesser. 1997. "Is It an Agent, or Just a Program?: A Taxonomy for Autonomous Agents." In *Intelligent Agents III Agent Theories, Architectures, and Languages*, edited by J. G. Carbonell, J. Siekmann, G. Goos, J. Hartmanis, J. Van Leeuwen, Jörg P. Müller, Michael J. Wooldridge, and Nicholas R. Jennings, 1193:21–35. Berlin, Heidelberg: Springer Berlin Heidelberg.
<https://doi.org/10.1007/BFb0013570>.
- Goodfellow, Ian J., Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. 2014. "Generative Adversarial Nets." In *Proceedings of the 28th International Conference on Neural Information Processing Systems - Volume 2*, 2672–80. NIPS'14. Cambridge, MA, USA: MIT Press.
- Harris, Zellig S. 1954. "Distributional Structure." *Word* 10 (2-3): 146–62.
- Hartmann, Jochen, Mark Heitmann, Christian Siebert, and Christina Schamp. 2023. "More Than a Feeling: Accuracy and Application of Sentiment Analysis." *International Journal of Research in Marketing* 40 (1): 75–87. <https://doi.org/10.1016/j.ijresmar.2022.05.005>.
- Hendrycks, Dan, Collin Burns, Steven Basart, Andy Zou, Mantas Mazeika, Dawn Song, and Jacob Steinhardt. 2021. "Measuring Massive Multitask Language Understanding." In *Proceedings of the International Conference on Learning Representations (ICLR)*. <https://openreview.net/pdf?id=d7KBjml3GmQ>.
- Jin, Can, Hongwu Peng, Shiyu Zhao, Zhenting Wang, Wujiang Xu, Ligong Han, Jiahui Zhao, Kai Zhong, Sanguthevar Rajasekaran, and Dimitris N. Metaxas. 2025. "APEER: Automatic Prompt Engineering Enhances Large Language Model Reranking." In *Companion Proceedings of the ACM Web Conference 2025 (WWW Companion '25)*, 1–10. ACM. <https://doi.org/10.1145/3701716.3717574>.
- Joos, Lucas, Daniel A Keim, and Maximilian T Fischer. 2025. "Cutting Through the Clutter: The Potential of LLMs for Efficient Filtration in Systematic Literature Reviews."

- Jordan, M. I., and T. M. Mitchell. 2015. "Machine Learning: Trends, Perspectives, and Prospects." *Science* 349 (6245): 255–60. <https://doi.org/10.1126/science.aaa8415>.
- Kapoor, Sayash, Benedikt Stroebl, Zachary S. Siegel, Nitya Nadgir, and Arvind Narayanan. 2024. "AI Agents That Matter." arXiv. <https://doi.org/10.48550/arXiv.2407.01502>.
- Köbis, Nils, Zoe Rahwan, Raluca Rilla, Bramantyo Ibrahim Supriyatno, Clara Bersch, Tamer Ajaj, Jean-François Bonnefon, and Iyad Rahwan. 2025. "Delegation to Artificial Intelligence Can Increase Dishonest Behaviour." *Nature*, 1–9.
- Lau, Oscar, and Su Golder. 2025. "Comparison of Elicit AI and Traditional Literature Searching in Evidence Syntheses Using Four Case Studies." *Cochrane Evidence Synthesis and Methods* 3 (6): e70050.
- LeCun, Yann, Yoshua Bengio, and Geoffrey Hinton. 2015. "Deep Learning." *Nature* 521 (7553): 436–44. <https://doi.org/10.1038/nature14539>.
- Li, Ying, Surabhi Datta, Majid Rastegar-Mojarad, Kyeryoung Lee, Hunki Paek, Julie Glasgow, Chris Liston, Long He, Xiaoyan Wang, and Yingxin Xu. 2025. "Enhancing Systematic Literature Reviews with Generative Artificial Intelligence: Development, Applications, and Performance Evaluation." *Journal of the American Medical Informatics Association* 32 (4): 616–25. <https://doi.org/10.1093/jamia/ocaf030>.
- Liu, Nelson F., Alex Tamkin, Nathanael Schärli, et al. 2023. "Lost in the Middle: How Language Models Use Long Contexts." *arXiv Preprint arXiv:2307.03172*. <https://arxiv.org/abs/2307.03172>.
- Luccioni, Sasha, Boris Gamazaychikov, Sara Hooker, Régis Pierrard, Emma Strubell, Yacine Jernite, and Carole-Jean Wu. 2024. "Light Bulbs Have Energy Ratings—so Why Can't AI Chatbots?" *Nature* 632 (8026): 736–38.
- Luo, Junyu, Weizhi Zhang, Ye Yuan, Yusheng Zhao, Junwei Yang, Yiyang Gu, Bohan Wu, et al. 2025. "Large Language Model Agent: A Survey on Methodology, Applications and Challenges." *arXiv Preprint arXiv:2503.21460*. <https://github.com/luo-junyu/Awesome-Agent-Papers>.

- Mialon, Grégoire, Clémentine Fourrier, Craig Swift, Thomas Wolf, Yann LeCun, and Thomas Scialom. 2023. "GAIA: A Benchmark for General AI Assistants." *arXiv Preprint arXiv:2311.12983*.
<https://arxiv.org/abs/2311.12983>.
- Mikolov, Tomas, Kai Chen, Greg Corrado, and Jeffrey Dean. 2013. "Efficient Estimation of Word Representations in Vector Space," September. <http://arxiv.org/abs/1301.3781>.
- Qiu, Rui, Shijie Chen, Yu Su, Po-Yin Yen, and Han-Wei Shen. 2025. "Completing a Systematic Review in Hours Instead of Months with Interactive AI Agents." *arXiv Preprint arXiv:2504.14822*.
- Rein, David, Betty Li Hou, Asa Cooper Stickland, Jackson Petty, Richard Yuanzhe Pang, Julien Dirani, Julian Michael, and Samuel R. Bowman. 2023. "GPQA: A Graduate-Level Google-Proof q&a Benchmark." *arXiv Preprint arXiv:2311.12022*. <https://arxiv.org/abs/2311.12022>.
- Rumelhart, David E, Geoffrey E Hinton, and Ronald J Williams. 1986. "Learning Representations by Back-Propagating Errors." *Nature* 323 (6088): 533–36.
- Sahoo, Pranab, Ayush Kumar Singh, Sriparna Saha, Vinija Jain, Samrat Mondal, and Aman Chadha. 2025. "A Systematic Survey of Prompt Engineering in Large Language Models: Techniques and Applications." *arXiv Preprint arXiv:2402.07927*. <https://arxiv.org/abs/2402.07927>.
- Santhanam, Keshav, Barlas Oguz, Sewon Min, Wen-tau Yih Chen, Jordan Boyd-Graber, Luke Zettlemoyer, and Mike Lewis. 2021. "LoTTE: Long-Tail Topic-Stratified Evaluation for IR." *arXiv Preprint arXiv:2112.01488*.
<https://arxiv.org/abs/2112.01488>.
- Schulhoff, Sander, Michael Ilie, Nishant Balepur, Konstantine Kahadze, Amanda Liu, Chenglei Si, Yinheng Li, Aayush Gupta, HyoJung Han, et al. 2025. "The Prompt Report: A Systematic Survey of Prompt Engineering Techniques." *arXiv Preprint arXiv:2406.06608*. <https://arxiv.org/abs/2406.06608>.
- Thakur, Nandan, Nils Reimers, Andreas Rücklé, Abhishek Srivastava, and Iryna Gurevych. 2021. "BEIR: A Heterogeneous Benchmark for Zero-Shot Evaluation of Information Retrieval Models." In *NeurIPS 2021*

- Datasets and Benchmarks Track*. <https://datasets-benchmarks-proceedings.neurips.cc/paper/2021/file/65b9eea6e1cc6bb9f0cd2a47751a186f-Paper-round2.pdf>.
- Tomczyk, Przemysław, Philipp Brügmann, Niklas Mergner, and Maria Petrescu. "Are AI Tools Better Than Traditional Tools in Literature Searching? Evidence from e-Commerce Research." *Journal of Librarianship and Information Science* 0 (0): 09610006241295802. <https://doi.org/10.1177/09610006241295802>.
- Tosi, Davide. 2025. "Comparing Generative AI Literature Reviews Versus Human-Led Systematic Literature Reviews: A Case Study on Big Data Research." *IEEE Access*.
- Vaswani, Ashish, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. 2017. "Attention Is All You Need." *Advances in Neural Information Processing Systems* 30.
- Vatsal, Shubham, and Harsh Dubey. 2024. "A Survey of Prompt Engineering Methods in Large Language Models for Different NLP Tasks." *arXiv Preprint arXiv:2407.12994*. <https://arxiv.org/abs/2407.12994>.
- Wang, Lei, Chen Ma, Xueyang Feng, Zeyu Zhang, Hao Yang, Jingsen Zhang, Zhi-Yuan Chen, et al. 2024. "A Survey on Large Language Model Based Autonomous Agents." *Frontiers of Computer Science*. <https://doi.org/10.1007/s11704-024-40231-1>.
- Yao, Shunyu, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan, and Yuan Cao. 2023. "ReAct: Synergizing Reasoning and Acting in Language Models." <https://react-lm.github.io/>.
- Zoph, Barret, Colin Raffel, Dale Schuurmans, Dani Yogatama, Denny Zhou, Don Metzler, Ed H. Chi, et al. 2022. "Emergent Abilities of Large Language Models." *TMLR*.